
Nina	Huacani	Steve Brandom	
A. Paterno	A. Materno	Nombres	
Inteligencia Artificial	PhD. Moises Silva	9990778	IV
Materia	Docente	CI	INICIAL A.P.

5. Del Dataset elegido, migre el mismo a WEKA y utilice cuatro técnicas de preprocesamiento (realice la captura de pantallas de estos por fases). Explique la razón de usar estas técnicas.


Preprocesamiento N°1: Remplazar valores faltantes

Paso 1. Abrimos el dataset y damos click a "Edit" para poder ver el dataset


#### Observamos campos vacíos




Paso 2. Vamos a la opción de Choose/filters/unsupervised/ReplaceMissingValues




Paso 3. Luego hacemos clic derecho sobre la opción elegida para poder ver las opciones que nos ofrece weka



Paso 4. Finalmente apretamos la opción de Apply para poder ver los cambios



Paso 5. Damos click en la pestaña de "Edit" para poder observar los cambios



Compararemos la técnica aplicada con el resultado obtenido en Python

## **Antes**

16	white	6.3	0.48	0.04	1.1	0.046
17	white	NaN	0.66	0.48	1.2	0.029
18	white	7.4	0.34	0.42	1.1	0.033
19	white	6.5	0.31	0.14	7.5	0.044
20	white	6.2	0.66	0.48	1.2	0.029
21	white	6.4	0.31	0.38	2.9	0.038
22	white	6.8	0.26	0.42	1.7	0.049
23	white	7.6	0.67	0.14	1.5	0.074
24	white	6.6	0.27	0.41	1.3	0.052
25	white	7.0	0.25	0.32	9.0	0.046
26	white	6.9	0.24	0.35	1.0	0.052
27	white	7.0	0.28	0.39	8.7	0.051
28	white	7.4	0.27	0.48	1.1	0.047
29	white	7.2	0.32	0.36	2.0	0.033
30	white	8.5	0.24	0.39	10.4	0.044
31	white	8.3	0.14	0.34	1.1	0.042
32	white	7.4	0.25	0.36	2 05	0.05
33	white	6.2	0.12	0.34	NaN	0.045

# Después

						_
17	white	7.2165793124710955	0.66	0.48	1.2	0.029
18	white	1.4	0.34	0.42	1.1	0.033
19	white	6.5	0.31	0.14	7.5	0.044
20	white	6.2	0.66	0.48	1.2	0.029
21	white	6.4	0.31	0.38	2.9	0.038
22	white	6.8	0.26	0.42	1.7	0.049
23	white	7.6	0.67	0.14	1.5	0.074
24	white	6.6	0.27	0.41	1.3	0.052
25	white	7.0	0.25	0.32	9.0	0.046
26	white	6.9	0.24	0.35	1.0	0.052
27	white	7.0	0.28	0.39	8.7	0.051
28	white	7.4	0.27	0.48	1.1	0.047
29	white	7.2	0.32	0.36	2.0	0.033
30	white	8.5	0.24	0.39	10.4	0.044
31	white	8.3	0.14	0.34	1.1	0.042
32	white	7.4	0.25	0.36	2.05	0.05
33	white	6.2	0.12	0.34	5.444326404926867	0.045
34	white	5.8	0.27	0.2	14.90	0.044

# Como podemos evidenciar obtenemos los mismos resultados

# **Missing Values**

La imputacion de valores faltantes es una tecnica de preprocesamiento muy importante ya que los algoritmos de aprendiza automatico no pueden manejar valores faltantes.

Habitualmente se asocian tres tipos de problemas con los valores faltantes:

- Perdida de eficiencia
- Complicaciones en el manejo y análisis de los datos
- Sesgo resultante de las diferencias entre los datos faltantes y los que están completos


Existe una amplia variedad de métodos de imputación como, por ejemplo: la sustitución por medias, medianas o modas, el vecindario K más cercano, procedimientos de máxima verosimilitud entre otras. Algunos de los beneficios de utilizar la imputación de valores faltantes son las siguientes.

la preservación de los datos: Ya que si se eliminara una tupla que contiene el valor faltante se pierde la información de las otras características de la fila o columna, la imputación de valores faltantes nos permite mantener la máxima cantidad de información posible.


**Consistencia de los datos:** Ayuda a mantener la consistencia de un conjunto de datos ya que es importante mantener el mismo número de muestras en todas las categorías para que el análisis sea el más optimo posible.

# Preprocesamiento N°2 Eliminar valores duplicados


Paso 1. Vamos a la opción de Choose/filters/unsupervised/instance/RemoveDuplicates



Paso 2. En la pestaña "Edit" podemos verificar que existen dos instancias repetidas



Paso 3. Configuramos la técnica de preprocesamiento y la aplicamos



Paso 4. Como podemos verificar se eliminó la instancia duplicada

## **Antes**


No.	Label	Count	Weight
1	white	4898	4898
2	red	1600	1600
Despues			
1	white	3970	3970
2	? red	1359	1359

# Comparacion de la técnica de preprocesamiento con Python

## **Antes**

	type	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	рΗ	sulphates	alcohol	quality
0	white	7.0	0.270	0.36	20.7	0.045	45.0	170.0	1.00100	3.00	0.450000	8.8	6
1	white	6.3	0.300	0.34	1.6	0.049	14.0	132.0	0.99400	3.30	0.490000	9.5	6
2	white	8.1	0.280	0.40	6.9	0.050	30.0	97.0	0.99510	3.26	0.440000	10.1	6
3	white	7.2	0.230	0.32	8.5	0.058	47.0	186.0	0.99560	3.19	0.400000	9.9	6
4	white	7.2	0.230	0.32	8.5	0.058	47.0	186.0	0.99560	3.19	0.400000	9.9	6
6493	red	5.9	0.550	0.10	2.2	0.062	39.0	51.0	0.99512	3.52	0.531235	11.2	6
6494	red	6.3	0.510	0.13	2.3	0.076	29.0	40.0	0.99574	3.42	0.750000	11.0	6
6495	red	5.9	0.645	0.12	2.0	0.075	32.0	44.0	0.99547	3.57	0.710000	10.2	5
6496	red	6.0	0.310	0.47	3.6	0.067	18.0	42.0	0.99549	3.39	0.660000	11.0	6
6497	red	6.0	0.310	0.47	3.6	0.067	18.0	42.0	0.99549	3.39	0.660000	11.0	6
6498 r	ows × 1	3 columns											

# **Despues**



Esta técnica de preprocesamiento se aplica para poder eliminar instancias duplicadas. Esto es especialmente útil cuando se trabaja con conjuntos de datos grandes y se quiere asegurar de que cada entrada sea única. La presencia de duplicados puede afectar negativamente a los análisis y modelos de aprendizaje automatico, ya que podría introducir sesgos o distorsiones en los resultados.


Algunas razones para utilizarlo:

**Datos de baja calidad**: Los conjuntos de datos pueden contener registros duplicados debido a errores de entrada o problemas en la recopilación de datos. Eliminar duplicados ayuda a limpiar el conjunto de datos y mejorar la calidad de los datos.


**Modelos de aprendizaje automatico:** Algunos algoritmos de aprendizaje automatico pueden ser sensibles a la presencia de duplicados. La existencia de registros duplicados puede conducir a un sobreajuste y afectar la capacidad del modelo para generalizar correctamente a nuevos datos.

## Preprocesamiento N°3: Estandarización

Paso 1. Vamos a la opción de Choose/filters/unsupervised/Standarize



Paso 2. Luego hacemos clic derecho sobre la opción elegida para poder ver las opciones que nos ofrece weka



Paso 3. Finalmente apretamos la opción de Apply para poder ver los cambios



Paso 4. Damos click en la pestaña de "Edit" para poder observar los cambios

_	Viewer	Quality-weka,filte	rs.unsupervised.att	ribute.Replace	Missing Values - we	ka.filters.unsu	ipervised.attribute.Stan	dardize					
		_						8: total sulfur dioxide Numeric	9: density Numeric	10: pH Numeric	11: sulphates Numeric	12: alcohol Numeric	13: <b>quality</b> Numeric
	white	-0.167145734	-0.42353100411	0.28422327	3.206730263412	-0.3151975	0.8155025413680453	0.9599017236653947	2.102051	-1.359	-0.54591708	-1.418449	6.0
2	white	-0.707372835	-0.24121295321	0.14651187	-0.80807430417	-0.2010118	-0.9310353922075265	0.2875954039075109	-0.23231	0.5080	-0.27704259	-0.831551	6.0
3	white	0.6817825673	-0.36275832048	0.55964608	0.305981413529	-0.1724653	-0.02959645874916	-0.33163410113264524	0.134514	0.2589	-0.61313570	-0.328495	6.0
1	white	-0.012795134	-0.66662173866	0.00880046	0.642300120762	0.0559062	0.9281824080503404	1.242978068826609	0.301255	-0.176	-0.88201019	-0.496180	6.0
5	white	-0.012795134	-0.66662173866	0.00880046	0.642300120762	0.0559062	0.9281824080503404	1.242978068826609	0.301255	-0.176	-0.88201019	-0.496180	6.0
5	white	0.6817825673	-0.36275832048	0.55964608	0.305981413529	-0.1724653	-0.02959645874916	-0.33163410113264524	0.134514	0.2589	-0.61313570	-0.328495	6.0
7	white	-0.784548135	-0.11966758593	-1.0928907	0.327001332731	-0.3151975	-0.02959645874916	0.35836449019781447	0.067818	-0.239	-0.41147983	-0.747708	6.0
3	white	-0.167145734	-0.42353100411	0.28422327	3.206730263412	-0.3151975	0.8155025413680453	0.9599017236653947	2.102051	-1.359	-0.54591708	-1.418449	6.0
)	white	-0.707372835	-0.24121295321	0.14651187	-0.80807430417	-0.2010118	-0.9310353922075265	0.2875954039075109	-0.23231	0.5080	-0.27704259	-0.831551	6.0
0	white	0.6817825673	-0.72739442229	0.76621319	-0.82909422338	-0.3437440	-0.1422763254314618	0.23451858918978324	-0.29901	0.0099	-0.54591708	0.4260871	6.0
1	white	0.6817825673	-0.42353100411	0.62850179	-0.83960418298	-0.6577549	-1.100055192230969	-0.9331713346002255	-1.29945	-1.421	0.193487764	1.2645127	5.0
2	white	1.0676590682	-0.66662173866	0.55964608	-0.26155640492	-0.6006620	-0.7620155921840841	-0.11932684226173455	0.001122	-0.488	-0.00816810	-0.663866	5.0
3	white	0.5274319670	-0.97048515684	0.35307898	-0.89215398098	-0.4579298	-0.8183555255252315	-0.7208640757293148	-0.89927	-0.239	0.664018121	0.2584020	5.0
4	white	-0.475846935	-1.09203052411	0.55964608	-0.82909422338	-0.3437440	0.9845223413914878	0.4822103912058457	-1.16606	2.0020	-0.07538672	1.5998829	7.0
5	white	0.8361331677	0.488059250421	2.07447154	2.901941434983	-0.4579298	0.5901428080034554	0.9952862668105464	1.835267	-1.484	0.932892611	-0.663866	5.0
6	white	-0.475846935	-1.03125784047	0.42193468	-0.82909422338	-0.6863013	-0.1422763254314618	-0.06625002754400688	-1.09936	0.1967	0.126269141	0.7614573	7.0
7	white	-0.707372835	0.852695352237	-1.9191592	-0.91317390018	-0.2866511	-0.02959645874916	-0.2962495579874935	-0.63249	0.1344	-1.15088468	-0.747708	6.0
8	white	-2.056363084	1.946603657686	1.11049170	-0.89215398098	-0.7719407	-0.08593639209031	-0.7208640757293148	-1.83302	0.6947	-0.94922881	1.9352531	8.0
9	white	0.1415554661	0.001877781332	0.69735749	-0.91317390018	-0.6577549	-0.7620155921840841	0.9775939952379706	-0.99931	-0.612	-0.00816810	0.6776148	6.0
20	white	-0.553022235	-0.18044026957	-1.2306021	0.432100928742	-0.3437440	0.1957632746154231	0.3052876754800868	0.267907	0.0099	-0.20982397	-0.831551	5.0
21	white	-0.784548135	1.946603657686	1.11049170	-0.89215398098	-0.7719407	-0.08593639209031	-0.7208640757293148	-1.83302	0.6947	-0.94922881	1.9352531	8.0
22	white	-0.630197535	-0.18044026957	0.42193468	-0.53481535455	-0.5150227	-0.6493357255017891	-0.2431727432697658	-1.16606	-0.301	-1.21810330	0.4260871	7.0
23	white	-0.321496334	-0.48430368775	0.69735749	-0.78705438497	-0.2010118	0.5901428080034554	0.11067268818175201	-0.56579	1.5662	-0.34426121	0.0068743	8.0
24	white	0.2959060665	2.007376341322	-1.2306021	-0.82909422338	0.5126493	-0.31129612545490	0.9245171805202429	-0.33235	-1.048	-0.14260534	-0.999236	5.0
25	white	-0.475846935	-0.42353100411	0.62850179	-0.87113406178	-0.1153724	-0.8183555255252315	0.4645181196332698	0.134514	1.2550	-0.41147983	-0.412338	6.0
26	white	-0.167145734	-0.54507637139	0.00880046	0.747399716772	-0.2866511	1.4352418081206677	2.2868220916085864	0.267907	0.1967	-0.20982397	-0.076968	6.0
27	white	-0.244321034	-0.60584905502	0.21536757	-0.93419381939	-0.1153724	0.25210320795657054	0.5352872059235734	-0.56579	1.4417	-0.61313570	-0.412338	6.0
28	white	-0.167145734	-0.36275832048	0.49079038	0.684339959166	-0.1439189	0.08308340793312811	0.4468258480606939	0.467995	1.0060	-0.00816810	0.0068743	6.0

## Compararemos la técnica aplicada con el resultado obtenido en Python

#### **Antes**

index	types	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pН	sulphates	alcohol	quality
0	white	7.0	0.27	0.36	20.7	0.045	45.0	170.0	1.001	3.0	0.45	8.8	6
1	white	6.3	0.3	0.34	1.6	0.049	14.0	132.0	0.994	3.3	0.49	9.5	6
2	white	8.1	0.28	0.4	6.9	0.05	30.0	97.0	0.9951	3.26	0.44	10.1	6
3	white	7.2	0.23	0.32	8.5	0.058	47.0	186.0	0.9956	3.19	0.4	9.9	6
4	white	7.2	0.23	0.32	8.5	0.058	47.0	186.0	0.9956	3.19	0.4	9.9	6
5	white	8.1	0.28	0.4	6.9	0.05	30.0	97.0	0.9951	3.26	0.44	10.1	6
6	white	6.2	0.32	0.16	7.0	0.045	30.0	136.0	0.9949	3.18	0.47	9.6	6
7	white	7.0	0.27	0.36	20.7	0.045	45.0	170.0	1.001	3.0	0.45	8.8	6
8	white	6.3	0.3	0.34	1.6	0.049	14.0	132.0	0.994	3.3	0.49	9.5	6
9	white	8.1	0.22	0.43	1.5	0.044	28.0	129.0	0.9938	3.22	0.45	11.0	6
10	white	8.1	0.27	0.41	1.45	0.033	11.0	63.0	0.9908	2.99	0.56	12.0	5
11	white	8.6	0.23	0.4	4.2	0.035	17.0	109.0	0.9947	3.14	0.53	9.7	5
12	white	7.9	0.18	0.37	1.2	0.04	16.0	75.0	0.992	3.18	0.63	10.8	5
13	white	6.6	0.16	0.4	1.5	0.044	48.0	143.0	0.9912	3.54	0.52	12.4	7
14	white	8.3	0.42	0.62	19.25	0.04	41.0	172.0	1.0002	2.98	0.67	9.7	5
15	white	6.6	0.17	0.38	1.5	0.032	28.0	112.0	0.9914	3.25	0.55	11.4	7
16	white	6.3	0.48	0.04	1.1	0.046	30.0	99.0	0.9928	3.24	0.36	9.6	6
17	white	7.2165793124710955	0.66	0.48	1.2	0.029	29.0	75.0	0.9892	3.33	0.39	12.8	8
18	white	7.4	0.34	0 42	11	0 033	17 0	171 0	0 9917	3 12	0.53	11.3	6

## **Despues**

index	types	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide
	white	-0.1671585992942454	-0.42356360223412876	0.2842451536932608	3.2069770773644866	-0.3152218461288419	0.8155653085446922	0.9599756048834102
1	white	-0.7074272804111803	-0.2412315187647987	0.14652314906116093	-0.8081364996226109	-0.2010272764791548	-0.9311070516567161	0.2876175394013979
2	white	0.6818350424609376	-0.3627862410776853	0.5596891629574614	0.3060049641486781	-0.17247863406673303	-0.02959873671405376	-0.33165962617413963
3	white	-0.012796118975121014	-0.6666730468599025	0.008801144429060652	0.6423495569852936	0.05591050523264102	0.928253847912525	1.2430737377179415
4	white	-0.012796118975121014	-0.6666730468599025	0.008801144429060652	0.6423495569852936	0.05591050523264102	0.928253847912525	1.2430737377179415
5	white	0.6818350424609376	-0.3627862410776853	0.5596891629574614	0.3060049641486781	-0.17247863406673303	-0.02959873671405376	-0.33165962617413963
6	white	-0.7846085205707422	-0.11967679645191175	-1.0929748926277405	0.3270265012009665	-0.3152218461288419	-0.02959873671405376	0.3583920726100308
7	white	-0.1671585992942454	-0.42356360223412876	0.2842451536932608	3.2069770773644866	-0.3152218461288419	0.8155653085446922	0.9599756048834102
8	white	-0.7074272804111803	-0.2412315187647987	0.14652314906116093	-0.8081364996226109	-0.2010272764791548	-0.9311070516567161	0.2876175394013979
9	white	0.6818350424609376	-0.727450408016346	0.7662721699056114	-0.8291580366748994	-0.3437704885412637	-0.14228727608188654	0.23453663949492326
10	white	0.6818350424609376	-0.42356360223412876	0.6285501652735112	-0.8396688052010436	-0.657805555077903	-1.1001398607084654	-0.933243158447519
11	white	1.0677412432587483	-0.6666730468599025	0.5596891629574614	-0.26157653626311067	-0.6007082702530594	-0.7620742426049669	-0.11933602654824106
12	white	0.5274725621418139	-0.9705598526421196	0.35310615600931095	-0.8922226478317647	-0.4579650581909506	-0.8184185122888833	-0.7209195588216204
13	white	-0.47588355993249415	-1.0921145749550065	0.5596891629574614	-0.8291580366748994	-0.3437704885412637	0.9845981175964413	0.4822475057251383
14	white	0.8361975227800627	0.4880968151125223	2.0746312139105627	2.902164790106304	-0.4579650581909506	0.5901882298090266	0.9953628714877266
15	white	-0.47588355993249415	-1.031337213798563	0.4219671583253611	-0.8291580366748994	-0.6863541974903247	-0.14228727608188654	-0.06625512664176642
16	white	-0 7074272804111803	0 8527609820511828	-1 9193069204203417	-0 9132441848840532	-0 28667320371642013	-0 02959873671405376	-0 29627235956982323

## Como podemos evidenciar obtenemos los mismos resultados

#### Estandarización

La estandarización es una técnica de preprocesamiento de datos que se utiliza para transformar las características de un conjunto de datos de forma que tengan una media en 0 y una desviación estándar de 1.

Algunas de las desventajas de trabajar con características no estandarizadas son las siguientes:


- Mayor sensibilidad a los valores atípicos, ya que pueden tener mayor impacto si es que la característica no esta estandarizada.
- Problemas de interpretación, puede ser difícil interpretar la importancia de una característica si no están en la misma escala.
- Dificultades en la visualización de los datos, Al graficar datos no estandarizados las diferencias en las escalas pueden dar origen a datos difíciles de interpretar

Algunos de los beneficios de estandarizar los datos son:


- Los algoritmos basados en la distancia como el k-NN reducen la desproporcionalidad que puedan existir en las características
- Convergencia rápida, algunos algoritmos de optimización convergen mucho más rápido cuando las características están en la misma escala, como en los algoritmos de descenso de gradiente.

# Preprocesamiento N°4: Discretización


## Paso N°1. Vamos a la opción de Choose/filters/unsupervised/Discretize



Paso 2. Luego hacemos click derecho sobre la opción elegida y escogemos el número de rango de precisión a 10.



Paso 3. Finalmente apretamos la opción de Apply para poder ver los cambios



Paso 4. Damos click en la pestaña de "Edit" para poder observar los cambios

	1: types Nominal	2: fixed acidity Nominal	3: volatile acidity Nominal	4: citric acid Nominal	5: residual sugar Nominal	6: chlorides Nominal	7: free sulfur dioxide Nominal	8: total sulfur dioxide Nominal	9: density Nominal	10: pH Nominal	11: sulphates Nominal	12: alcohol Nominal	13: quality Numeric
	white	'(0.2-0.3]'	'(0.1-0.2]'	'(0.2-0.3]'	'(0.3-0.4]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.3-0.4]'	'(0.2-0.3]'	'(0.2-0	'(0.1-0.2]'	'(0.1-0.2]'	6.0
	white	'(0.2-0.3]'	'(0.1-0.2]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.2-0.3]'	'(0.1-0.2]'	'(0.4-0	'(0.1-0.2]'	'(0.2-0.3]'	6.0
	white	'(0.3-0.4]'	'(0.1-0.2]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.2-0.3]'	'(0.1-0.2]'	'(0.4-0	'(0.1-0.2]'	'(0.3-0.4]'	6.0
	white	'(0.2-0.3]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.1-0.2]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.4-0.5]'	'(0.1-0.2]'	'(0.3-0	'(0.1-0.2]'	'(0.2-0.3]'	6.0
	white	'(0.2-0.3]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.1-0.2]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.4-0.5]'	'(0.1-0.2]'	'(0.3-0	'(0.1-0.2]'	'(0.2-0.3]'	6.0
	white	'(0.3-0.4]'	'(0.1-0.2]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.2-0.3]'	'(0.1-0.2]'	'(0.4-0	'(0.1-0.2]'	'(0.3-0.4]'	6.0
	white	'(0.1-0.2]'	'(0.1-0.2]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.2-0.3]'	'(0.1-0.2]'	'(0.3-0	'(0.1-0.2]'	'(0.2-0.3]'	6.0
	white	'(0.2-0.3]'	'(0.1-0.2)'	'(0.2-0.3]'	'(0.3-0.4]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.3-0.4]'	'(0.2-0.3]'	'(0.2-0	'(0.1-0.2]'	'(0.1-0.2)'	6.0
	white	'(0.2-0.3]'	'(0.1-0.2]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.2-0.3]'	'(0.1-0.2]'	'(0.4-0	'(0.1-0.21'	'(0.2-0.3]'	6.0
0	white	'(0.3-0.4]'	'(-inf-0.1]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.2-0.3]'	'(0.1-0.2]'	'(0.3-0	'(0.1-0.2]'	'(0.4-0.5]'	6.0
1	white	'(0.3-0.4]'	'(0.1-0.2]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(-inf-0.1]'		'(0.1-0.2]'	'(0.5-0.6]'	5.0
2	white	'(0.3-0.41'	'(-inf-0.11'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.2-0.3]'	'(0.1-0.2]'		'(0.1-0.2]'	'(0.2-0.31'	5.0
3	white	'(0.3-0.4]'	'(-inf-0.1]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(-inf-0.1]'		'(0.2-0.3]'	'(0.4-0.5]'	5.0
4	white	'(0.2-0.31'	'(-inf-0.11'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.3-0.4]'	'(-inf-0.1]'		'(0.1-0.2]'	'(0.6-0.71'	7.0
5	white	'(0.3-0.4]'	'(0.2-0.3]'	'(0.3-0.4]'	'(0.2-0.31'	'(-inf-0.1]'	'(0.1-0.21'	'(0.3-0.41'	'(0.2-0.3]'		'(0.2-0.3]'	'(0.2-0.3]'	5.0
6	white	'(0.2-0.3]'	'(-inf-0.1]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.2-0.3]'	'(-inf-0.1]'		'(0.1-0.2]'	'(0.4-0.5]'	7.0
7	white	'(0.2-0.3]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.2-0.3]'	'(0.1-0.21'		'(-inf-0.1]'	'(0.2-0.3]'	6.0
8	white	'(0.2-0.3]'	'(0.3-0.4)'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(-inf-0.1]'	-	'(-inf-0.1]'	'(0.6-0.7)'	8.0
9	white	'(0.2-0.3]'	'(0.1-0.2)'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.3-0.4]'	'(-inf-0.1]'	-	'(0.1-0.21'	'(0.4-0.5]'	6.0
0	white	'(0.2-0.3]'	'(0.1-0.2)'	'(-inf-0.11'	'(0.1-0.2]'	'(-inf-0.11'	'(0.1-0.21'	'(0.2-0.3]'	'(0.1-0.21'		'(0.1-0.21'	'(0.2-0.31'	5.0
1	white	'(0.1-0.2]'	'(0.3-0.41'	'(0.2-0.31'	'(-inf-0.1]'	'(-inf-0.11'	'(-inf-0.11'	'(0.1-0.2]'	'(-inf-0.11'		'(-inf-0.1]'	'(0.6-0.71'	8.0
2	white	'(0.2-0.31'	'(0.1-0.21'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.11'	'(-inf-0.11'	'(0.2-0.31'	'(-inf-0.11'		'(-inf-0.1]'	'(0.4-0.51'	7.0
3	white	'(0.2-0.31'	'(0.1-0.2)'	'(0.2-0.31'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.21'	'(0.2-0.31'	'(0.1-0.2]'		'(0.1-0.2]'	'(0.3-0.41'	8.0
4	white	'(0.3-0.4]'	'(0.3-0.4)'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(-inf-0.1]'	'(0.3-0.4]'	'(0.1-0.2]'		'(0.1-0.2]'	'(0.1-0.2]'	5.0
5	white	'(0.2-0.3]'	'(0.1-0.2)'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.3-0.4]'	'(0.1-0.2]'		'(0.1-0.2]'	'(0.2-0.3]'	6.0
6	white	'(0.2-0.3]'	'(0.1-0.2)'	'(0.1-0.2]'	'(0.1-0.2]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.5-0.6]'	'(0.1-0.2]'		'(0.1-0.2]'	'(0.3-0.4]'	6.0
7	white	'(0.2-0.3]'	'(0.1-0.2]'	'(0.2-0.3]'	'(-inf-0.1]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.3-0.4]'	'(0.1-0.2]'		'(0.1-0.2]'	'(0.2-0.3]'	6.0
8	white	'(0.2-0.3]'	'(0.1-0.2]'	'(0.2-0.3]'	'(0.1-0.2]'	'(-inf-0.1]'	'(0.1-0.2]'	'(0.3-0.4]'	'(0.1-0.2]'		'(0.1-0.2]'	'(0.3-0.4]'	6.0
n		(0.2 0.3)	(011 012)	(0.2 0.3)	17 (mg n 41)	17 := £ 0.11	17:-4 0 111	100 2 0 211	17 :-E A 11		(0.1 0.2)	1/0 E 0 E11	6.0
	Nan	d attribute ne: volatil ng: 0 (0%)			Dist	inct: 10			Type Unique	: Non			
	No.		L	abel			Cour	it			We	ight	

ssing:	0 (0%)	Distinct: 10	Unique: 1 (0%)
No.	Label	Count	Weight
1	'(-inf-0.1]'	1799	1799
2	'(0.1-0.2]'	2883	2883
3	'(0.2-0.3]'	934	934
4	'(0.3-0.4]'	583	583
5	'(0.4-0.5]'	203	203
6	'(0.5-0.6]'	69	69
7	'(0.6-0.7]'	20	20
8	'(0.7-0.8]'	3	3
9	'(0.8-0.9]'	2	2

#### Discretizacion

Su principal objetivo es transformar un conjunto de atributos continuos en discretos, asociando valores categóricos a intervalos y transformando así datos cuantitativos en datos cualitativos. Los problemas más comunes que ocurren cuando no se discretizan los datos son los siguientes

- Dificultad en la identificación de patrones: En algunos casos, si las variables son continuas, los patrones pueden ser más difíciles de identificar, especialmente para modelos que funcionan mejor con variables discretas.
- Sensibilidad al ruido: Las variables continuas pueden estar sujetas a ruido en los datos.
   Esto puede hacer que los modelos sean más sensibles a pequeñas variaciones en los valores.

• Interpretación más difícil: Interpretar los resultados de un modelo que trabaja con variables continuas puede ser más complicado que si se utilizan variables discretas.

Algunos de los beneficios de discretizar son:

- Reducción de complejidad: En algunos casos, trabajar con variables discretas puede simplificar el análisis y hacer que los modelos sean más fáciles de entender y de comunicar.
- Requisitos de algunos modelos: Algunos algoritmos de aprendizaje automático, como árboles de decisión o reglas de asociación, requieren que las variables sean discretas.
- Control del ruido y redundancia: La discretización puede ayudar a reducir el ruido en los datos, ya que se agrupan valores similares. También puede eliminar redundancias al agrupar valores cercanos.